

Основы матричных вычислений, Экзамен (Теория)

Версия от 27.06.2021 15:35

Содержание

Связь прямой и обратной ошибок через число обусловленности.	2
Критерий сходимости ряда Неймана.	3
Существование и единственность LU и LDL разложений.	4
Теорема о сходимости градиентного спуска для линейной системы с симметричной положительно определенной матрицей.	6
Оценка сходимости метода сопряженных градиентов для линейной системы с произвольной симметричной положительно определенной матрицей. Случай $\lambda_1 \gg \lambda_2$.	7
Сходимость степенного метода для диагонализуемых матриц.	9
Вывод двух основных свойств QR алгоритма.	10
Теорема Леви-Деспланка и первая теорема Гершгорина.	11
Теорема Леви-Деспланка.	11
Теорема Гершгорина.	11

Связь прямой и обратной ошибок через число обусловленности.

Вспомним кто есть ошибки:

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} \text{ — прямая ошибка, где } f \text{ — точное решение, а } \tilde{f} \text{ — алгоритм}$$

$$\frac{\|\tilde{x} - x\|}{\|x\|} \text{ — обратная ошибка, где } \tilde{x} : f(\tilde{x}) = \tilde{f}(x)$$

Предположим, что наша задача обратна устойчива, а именно: $f(\tilde{x}) = \tilde{f}(x)$, $\frac{\|\tilde{x} - x\|}{\|x\|} = O(\varepsilon_{machine})$

$$\begin{aligned} \text{forward_err} &= \frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} \\ &= \frac{\|f(\tilde{x}) - f(x)\|}{\|f(x)\|} \\ &= \frac{\|f(x + \Delta x) - f(x)\|}{\|f(x)\|} \\ &= \frac{\|f(x) + f'(x) \cdot \Delta x + O(\|\Delta x\|^2) - f(x)\|}{\|f(x)\|} \\ &= \frac{\|f'(x) \cdot \frac{\Delta x}{\|\Delta x\|} + O(\|\Delta x\|)\|}{\|f(x)\|} \cdot \|\Delta x\| \\ &\leq \frac{\|f'(x) \cdot \frac{\Delta x}{\|\Delta x\|}\| + O(\|\Delta x\|)}{\|f(x)\|} \cdot \|\Delta x\| \\ &\leq \frac{\|f'(x)\| + O(\|\Delta x\|)}{\|f(x)\|} \cdot \|\Delta x\| \\ &= \frac{\|f'(x)\| \cdot \|x\| + O(\|\Delta x\|) \cdot \|x\|}{\|f(x)\|} \cdot \frac{\|\Delta x\|}{\|x\|} \\ &= \left(\frac{\|f'(x)\| \cdot \|x\|}{\|f(x)\|} + \underbrace{\frac{O(\|\Delta x\|) \cdot \|x\|}{\|f(x)\|}}_{=O(\|\Delta x\|) \text{ в силу фиксированности } x} \right) \cdot \frac{\|\Delta x\|}{\|x\|} \\ &= (\text{cond}(f, x) + O(\|\Delta x\|)) \cdot \text{backward_err} \\ &= (\text{cond}(f, x) + O(\varepsilon_{machine})) \cdot \text{backward_err} \\ &\approx \text{cond}(f, x) \cdot \text{backward_err} \end{aligned}$$

Критерий сходимости ряда Неймана.

Напомним определение спектрального радиуса $\rho(A) = \max_i |\lambda_i(A)| = \lim_{k \rightarrow \infty} \|A^k\|^{1/k}$

Критерий сходимости ряда Неймана: $\sum_{i=0}^k A^k$ сходится $\iff \rho(A) < 1$.

\ominus : $A = UTU^{-1}$ — разложение Шура (здесь T верхнетреугольная).

Введем матрицу $D_\varepsilon = \text{diag}(1, \varepsilon, \dots, \varepsilon^{n-1})$. Оказывается, что $(D_\varepsilon^{-1}TD_\varepsilon)_{ij} = \varepsilon^{j-i}t_{ij}$, то есть каждый элемент верхнего треугольника домножается на эpsilon в какой-то степени. Нижний треугольник — нули, так как T верхнетреугольная. Остаются $|t_{ii}|$ — но это модули собственных значений, а из $\rho(T) < 1$ следует что все меньше единицы.

Из этого следует, что $\exists \varepsilon : \|D_\varepsilon^{-1}TD_\varepsilon\|_1 < 1$. То есть $\sum_{k=0}^{\infty} (D_\varepsilon^{-1}TD_\varepsilon)^k = \sum_{k=0}^{\infty} D_\varepsilon^{-1}T^kD_\varepsilon$ сходится.

Вынесем по матрице слева и справа, сходимость не сломается: $\sum_{k=0}^{\infty} T^k$ сходится.

Теперь занесем по матрице слева и справа, но уже другие, тогда $\sum_{k=0}^{\infty} UT^kU^{-1} = \sum_{k=0}^{\infty} (UTU^{-1})^k$ сходится.

\ominus : пусть $\rho(A) \geq 1 \implies \exists |\lambda_i| > 1$, но ряд сходится.

$\exists \|x\|_2 = 1 : Ax = \lambda_i x \implies A^k x = \lambda_i^k x$.

$\|A^k\|_2 = \|A^k\|_2 \|x\|_2 \geq \|A^k x\|_2 = \|\lambda^k x\|_2 = |\lambda^k| \|x\|_2 = |\lambda^k| \geq 1$, то есть $\|A^k\|_2 \not\rightarrow 0$, получается ряд не сходится.

Существование и единственность LU и LDL разложений.

Определение. Пусть есть матрица $A \in \mathbb{R}^{n \times n}$. Разложение $A = LU$ называется LU -разложением, если матрица L нижнетреугольная с единицами на диагонали, а матрица U верхнетреугольная.

Определение. Матрица A называется **строго регулярной**, если все её ведущие подматрицы невырождены. (ведущие подматрицы — верхние левые $k \times k$ блоки).

Теорема (Существование LU -разложения). Пусть $\det(A) \neq 0$. Тогда A имеет LU -разложение $\iff A$ строго регулярна.

Доказательство.

⊖

A имеет LU -разложение, то есть $A = LU$.

Мы знаем, что матрица невырождена, то есть

$$0 \neq \det(A) = \underbrace{\det(L)}_1 \det(U) = u_{11} \cdot \dots \cdot u_{nn}.$$

Следовательно, $u_{kk} \neq 0$ для любого $k \in \{1, \dots, n\}$. Далее нам надо убедиться, что матрица A строго регулярна. То есть, надо проверить что ведущие подматрицы тоже невырождены. Запишем для ведущих подматриц:

$$A = \begin{pmatrix} L_k & 0 \\ * & * \end{pmatrix} \begin{pmatrix} U_k & * \\ 0 & * \end{pmatrix} = \begin{pmatrix} L_k U_k & * \\ * & * \end{pmatrix}.$$

Обозначим $A_k := L_k U_k$. Тогда $\det(A_k) = \underbrace{\det(L_k)}_1 \det(U_k) = u_{11} \cdot \dots \cdot u_{kk} \neq 0$, аналогично случаю с полной матрицей.

⊖

Доказываем по индукции. Мы считаем, что пусть для $n - 1$ уже доказано утверждение. Докажем для n .

Пусть матрица $A = \begin{pmatrix} a & c^T \\ b & D \end{pmatrix}$. Здесь a — число, не равное нулю в силу строгой регулярности, D — матрица $(n - 1) \times (n - 1)$.

Мы считаем, что для D мы уже умеем искать LU — разложение. Давайте попробуем преобразовать нашу матрицу, чтобы она привелась к блочно-верхнетреугольному виду:

$$\begin{pmatrix} 1 & 0 \\ -\frac{1}{a}b & I \end{pmatrix} \begin{pmatrix} a & c^T \\ b & D \end{pmatrix} = \begin{pmatrix} a & c^T \\ 0 & D - \frac{1}{a}bc^T \end{pmatrix} =: A'.$$

Блок $D - \frac{1}{a}bc^T$ называется дополнением по Шуру матрицы A . Обозначим $A_1 := D - \frac{1}{a}bc^T$.

Докажем, что A_1 строго регулярна (было в ДЗ). A' получилась из A с помощью $n - 1$ -го элементарного преобразования первого типа (вычесть из строки другую, домноженную на коэффициент). Помним, что такие элементарные преобразования не меняют определитель матрицы, поэтому $0 \neq \Delta_k(A) = \Delta_k(A')$ для любого $k \in \{1, \dots, n\}$. (здесь $\Delta_k(A)$ — главный угловой минор матрицы A). Но в матрице A' мы видим угол нулей, поэтому $0 \neq \Delta_k(A') = a \cdot \Delta_{k-1}(A_1)$ для любого $k \in \{1, \dots, n\}$. Следовательно, $\Delta_i(A_1) \neq 0$ для любого $i \in \{1, \dots, n - 1\} \implies A_1$ строго регулярна.

Продолжим доказательство теоремы. По предположению индукции тогда считаем, что A_1 имеет LU -разложение:

$D - \frac{1}{a}bc^T = A_1 = L_1 U_1$. Этого уже достаточно для того, чтобы построить LU -разложение самой матрицы A :

$$\begin{pmatrix} 1 & 0 \\ \frac{1}{a}b & L_1 \end{pmatrix} \begin{pmatrix} a & c^T \\ 0 & U_1 \end{pmatrix} = \begin{pmatrix} a & c^T \\ b & \frac{1}{a}bc^T + L_1 U_1 \end{pmatrix} = \begin{pmatrix} a & c^T \\ b & D \end{pmatrix}.$$

■

Утверждение. LU -разложение определяется единственным образом.

Доказательство.

Предположим, что есть два разложения:

$$A = L_1 U_1 = L_2 U_2.$$

Преобразуем равенство:

$$L_2^{-1} L_1 = U_2 U_1^{-1}.$$

Обратная к нижнетреугольной матрице — нижнетреугольная матрица, и произведение нижнетреугольных — тоже нижнетреугольная. Для верхнетреугольных то же самое. Значит, $L_2^{-1} L_1$ — диагональная матрица. Более того, это единичная матрица (в силу того, что на диагонали матриц L_2 и L_1 стоят 1). Значит,

$$L_1 = L_2;$$

$$U_1 = U_2.$$

■

Следствие (LDL -разложение). Пусть $A \in \mathbb{C}^{n \times n}$ является строго регулярной и $A = A^*$. Тогда $\exists L$ — нижнетреугольная и D — диагональная, такие что

$$A = LDL^*.$$

Доказательство.

A — строго регулярна, следовательно,

$$A = LU = L \underset{\text{diag}(u_{11}, \dots, u_{nn})}{D} D^{-1} U = A^* = (U^* D^{-*})(D^* L^*)$$

Но LU -разложение единственно, следовательно, $L = U^* D^{-*}$. Значит, $U = DL^*$. Доказали. ■

Теорема о сходимости градиентного спуска для линейной системы с симметричной положительно определенной матрицей.

Теорема (Сходимость наискорейшего спуска). Пусть $A = A^T > 0$ и x_k сгенерированного с помощью метода наискорейшего спуска, тогда для ошибки $e_k := x_* - x_k$ справедливо:

$$\|e_{k+1}\|_A \leq \frac{\text{cond}_2(A) - 1}{\text{cond}_2(A) + 1} \|e_k\|_A$$

Доказательство. Заметим, что оценку лучше действительно нельзя получить, но данным доказательством мы не отвечаем на вопрос почему это так.

1. Уже обсуждалось, что нам без разницы: минимизировать $f(x)$ или честную A -норму ошибки, $\|x - x_*\|_A^2$. Результат не должен поменяться, поэтому для теоретических выкладок мы будем минимизировать именно честную A -норму ошибки.

$$\begin{aligned} 2f(x) + \text{const} &= \|x - x_*\|_A^2 \Rightarrow \\ \Rightarrow \tau_k &= \underset{\tau}{\operatorname{argmin}} f(x_k + \tau r_k) = \underset{\tau}{\operatorname{argmin}} \|x_k + \tau r_k - x_*\|_A^2 \end{aligned}$$

2. Теперь запишем A -норму ошибки, сдвиг вдоль градиента на параметр τ хотим выбрать оптимальным образом из условия минимизации $\|x_k + \tau r_k - x_*\|_A^2$.

$$\begin{aligned} \|e_{k+1}\|_A^2 &\stackrel{1.}{=} \min_{\tau} \|x_k + \tau r_k - x_*\|_A^2 \stackrel{\forall t}{\leq} \|x_k + t r_k - x_*\|_A^2 = \left[\text{т.к. } x_k - x_* = e_k \text{ и } r_k = -A e_k \right] = \|(I - tA)e_k\|_A^2 = \\ &= \left[\text{теперь вспомним про } A = A^T \text{ и заметим, что } \|y\|_A^2 = y^T A y = y^T A^{1/2} A^{1/2} y = (A^{1/2} y)^T A^{1/2} y = \|A^{1/2} y\|_2^2 \right] = \\ &= \|A^{1/2}(I - tA)e_k\|_2^2 = \|(I - tA)A^{1/2}e_k\|_2^2 \leq \|I - tA\|_2^2 \cdot \|e_k\|_A^2 \end{aligned}$$

3. В предыдущем пункте мы свели все ко второй норме, для которой уже доказывали оценку из теоремы. Остается только выбрать $t = \frac{2}{\lambda_1 + \lambda_n}$, для которого как раз работает необходимая оценка.

■

Оценка сходимости метода сопряженных градиентов для линейной системы с произвольной симметричной положительно определенной матрицей. Случай $\lambda_1 \gg \lambda_2$.

Предложение. Для $A = A^\top > 0$ и любого многочлена $h(\lambda) : h(0) = 1$ степени k верно:


$$\|e_k\|_A \leq \max_i |h(\lambda_i)| \|e_0\|_A$$

В общем случае мы использовали многочлен вида:

$$t_k(\lambda) = \frac{T_k\left(\frac{\lambda_1 + \lambda_n - 2\lambda}{\lambda_1 - \lambda_n}\right)}{T_k\left(\frac{\lambda_1 + \lambda_n}{\lambda_1 - \lambda_n}\right)}$$

Где T_k - многочлен Чебышева. Такой t_k меньше всего отклоняется от 0 на отрезке $[\lambda_n, \lambda_1]$, однако чем больше отрезок тем больше мы отклоняемся. Вообще говоря нас интересует отклонение только в точках $\lambda \in \{\lambda_1, \lambda_2, \dots, \lambda_n\}$. Давайте рассмотрим другой многочлен:

$$p_k(\lambda) = \frac{T_{k-1}\left(\frac{\lambda_2 + \lambda_n - 2\lambda}{\lambda_2 - \lambda_n}\right)}{T_{k-1}\left(\frac{\lambda_2 + \lambda_n}{\lambda_2 - \lambda_n}\right)} \left(1 - \frac{\lambda}{\lambda_1}\right)$$



(Заметка: на лекции путаница с знаком знаменателя аргумента T_i)

То есть мы уменьшили отрезок, а также пожертвовав степенью многочлена Чебышева, мы добавили множитель который обращается в 0 при $\lambda = \lambda_1$

Нам нужно оценить $\max_i |p_k(\lambda_i)|$, заметим, что:

$$\max_i |p_k(\lambda_i)| \leq \max_{\lambda \in [\lambda_n, \lambda_2] \cup \{\lambda_1\}} |p_k(\lambda)| = \max_{\lambda \in [\lambda_n, \lambda_2]} |p_k(\lambda)|$$

Предложение. С лекции 14 нам известно:

$$\frac{T_k\left(\frac{a+b-2\lambda}{a-b}\right)}{T_k\left(\frac{a+b}{a-b}\right)} \leq 2 \left(\frac{\sqrt{\frac{a}{b}} - 1}{\sqrt{\frac{a}{b}} + 1}\right)^k$$

Теперь оценим p_k на множестве $[\lambda_n, \lambda_2]$:

$$p_k(\lambda) = \frac{T_{k-1}\left(\frac{\lambda_2 + \lambda_n - 2\lambda}{\lambda_2 - \lambda_n}\right)}{T_{k-1}\left(\frac{\lambda_2 + \lambda_n}{\lambda_2 - \lambda_n}\right)} \left(1 - \frac{\lambda}{\lambda_1}\right) \leq 2 \left(1 - \frac{\lambda}{\lambda_1}\right) \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1}\right)^{k-1} \leq 2 \left(1 - \frac{\lambda_n}{\lambda_1}\right) \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1}\right)^{k-1}$$

Осталось заметить, что $\left|1 - \frac{\lambda_n}{\lambda_1}\right| \leq 1$, тогда:

$$p_k(\lambda) \leq 2 \left(1 - \frac{\lambda_n}{\lambda_1}\right) \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1}\right)^{k-1} \leq 2 \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1}\right)^{k-1}$$

Заметим, что:

$$0 \leq 2 \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1} \right)^{k-1} \implies |p_k(\lambda)| \leq 2 \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1} \right)^{k-1}$$

Используя первое предложение можно сделать вывод:

$$\|e_k\|_A \leq 2 \left(\frac{\sqrt{\frac{\lambda_2}{\lambda_n}} - 1}{\sqrt{\frac{\lambda_2}{\lambda_n}} + 1} \right)^{k-1} \|e_0\|_A$$

Сходимость степенного метода для диагонализуемых матриц.

Дано: A — диагонализуемая и $\lambda^{(1)}$ — простое ($|\lambda^{(1)}| > |\lambda^{(2)}| \geq \dots \geq |\lambda^{(n)}|$).

Доказать: отношение Релея $R(Ax_k, x_k) = \frac{(Ax_k, x_k)}{(x_k, x_k)} = (Ax_k, x_k)$ сходится к $\lambda^{(1)}$ — старшему собственному значению.

Доказательство. Поскольку A диагонализуемая, то существует n линейно независимых собственных векторов $v^{(i)}$, далее считаем, что $\|v^{(i)}\| = 1$. В таком случае $x_0 = \alpha_1 v^{(1)} + \dots + \alpha_n v^{(n)}$. **Ключевой момент:** считаем, что $\alpha_1 \neq 0$. Мы используем это в доказательстве, а в противоположном случае метод вообще сойдётся не пойми куда, но точно не туда, куда надо было.

$$\begin{aligned} x_k &= \frac{Ax_{k-1}}{\|Ax_{k-1}\|_2} = \frac{A^k x_0}{\|A^k x_0\|_2} = \frac{\alpha_1 (\lambda^{(1)})^k v^{(1)} + \dots + \alpha_n (\lambda^{(n)})^k v^{(n)}}{\|\alpha_1 (\lambda^{(1)})^k v^{(1)} + \dots + \alpha_n (\lambda^{(n)})^k v^{(n)}\|_2} \\ &= \left(\frac{\lambda^{(1)}}{|\lambda^{(1)}|} \right)^k \cdot \left(\frac{\alpha_1}{|\alpha_1|} \right)^k \cdot \frac{v^{(1)} + \frac{\alpha_2}{\alpha_1} \left(\frac{\lambda^{(2)}}{\lambda^{(1)}} \right)^k v^{(2)} + \dots + \frac{\alpha_n}{\alpha_1} \left(\frac{\lambda^{(n)}}{\lambda^{(1)}} \right)^k v^{(n)}}{\left\| v^{(1)} + \frac{\alpha_2}{\alpha_1} \left(\frac{\lambda^{(2)}}{\lambda^{(1)}} \right)^k v^{(2)} + \dots + \frac{\alpha_n}{\alpha_1} \left(\frac{\lambda^{(n)}}{\lambda^{(1)}} \right)^k v^{(n)} \right\|_2} \\ &= e^{i\varphi} \cdot \frac{v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)}{\left\| v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right) \right\|_2} \ominus \end{aligned}$$

Знаменатель равен $1 + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)$, разложим $\frac{1}{1 + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)}$ по Тейлору и получим $1 + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)$, откуда:

$$\begin{aligned} &\ominus e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)) (1 + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)) \\ &= e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)) \end{aligned}$$

Отсюда имеем:

$$\begin{aligned} R(x_k) &= (Ax_k, x_k) = (A \cdot (e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right))))^T \cdot (e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right))) \\ &= (e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)))^T A (e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right))) \\ &= (e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)))^T (e^{i\varphi} \cdot (\lambda^{(1)} v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right))) \\ &= \lambda^{(1)} \cdot \left\| e^{i\varphi} \cdot (v^{(1)} + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)) \right\|_2 \\ &= \lambda^{(1)} \cdot (1 + O\left(\left(\frac{\lambda^{(2)}}{\lambda^{(1)}}\right)^k\right)) \end{aligned}$$

■

Вывод двух основных свойств QR алгоритма.

Теорема Леви-Деспланка и первая теорема Гершгорина.

Теорема Леви-Деспланка.

Определение. Матрица A обладает строгим строчным диагональным преобладанием, если $\forall i |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$.

Определение. Матрица A обладает строгим столбцовым диагональным преобладанием, если $\forall j |a_{jj}| > \sum_{i=1, i \neq j}^n |a_{ij}|$.

Теорема (Леви-Деспланка). Матрица, обладающая строгим строчным (столбцовым) диагональным преобладанием является невырожденной.

Доказательство.

Докажем для строгого строчного, для столбцового аналогично.

Представим A в следующем виде: $A = \text{diag}(A)(I + \text{diag}(A)^{-1})(A - \text{diag}(A))$, где матрица $\text{diag}(A)$ – это диагональная матрица, у которой на диагонали стоят диагональные элементы матрицы A . Раскрыв скобки, можно проверить, что равенство действительно выполняется.

Вспомним немного из курса линала:

- Матрица A – обратима \Leftrightarrow матрица A – невырожденна
- Если $A = BC$, то $\det(A) = \det(B) \cdot \det(C)$

Таким образом, нам необходимо и достаточно доказать обратимость матриц $\text{diag}(A)$ и $(I + \text{diag}(A)^{-1})(A - \text{diag}(A))$.

Обратимость первой почти очевидна: если бы на диагонали могли стоять нулевые элементы, то матрица A не обладала бы строгим строчным диагональным преобладанием.

Теперь заметим, что $(I + \text{diag}(A)^{-1})(A - \text{diag}(A))$ обратима $\Leftrightarrow \exists \sum_{k=0}^{\infty} (-\text{diag}(A)^{-1})(A - \text{diag}(A))^k$ (вспоминаем про ряды Неймана).

Осталось доказать, что такой ряд Неймана сходится. Не будем использовать критерий, а используем признак: докажем, что $\|\text{diag}(A)^{-1}(A - \text{diag}(A))\| < 1$ для некоторой нормы.

Рассмотрим бесконечную норму: $\|\text{diag}(A)^{-1}(A - \text{diag}(A))\|_{\infty} < 1$. Пусть это неравенство не выполняется, тогда: $\max_i \frac{\sum_{j=1, j \neq i}^n |a_{ij}|}{|a_{ii}|} \geq 1$ (это я просто руками записала бесконечную норму для матрицы). Но тогда выходит, что A не обладает строгим строчным диагональным преобладанием – противоречие $\Rightarrow \|\text{diag}(A)^{-1}(A - \text{diag}(A))\|_{\infty} < 1 \Rightarrow \sum_{k=0}^{\infty} (-\text{diag}(A)^{-1})(A - \text{diag}(A))^k$ – сходится $\Rightarrow (I + \text{diag}(A)^{-1})(A - \text{diag}(A))$ обратима.

Таким образом, A представляет собой произведение обратимых матриц $\Rightarrow A$ и сама обратима, то есть, невырожденна. ■

Теорема Гершгорина.

Теорема (1-я теорема Гершгорина). Пусть $A \in \mathbb{C}$, тогда собственные значения матрицы A находятся внутри

$$D = D_1 \cup D_2 \cup \dots \cup D_n$$

где

$$D_k = \{z \in \mathbb{C} : |a_{kk} - z| \leq \sum_{i \neq k} |a_{ki}|\}$$

Доказательство.

Пусть $\lambda \notin D \Rightarrow A - I\lambda$ обладает строгим строчным диагональным преобладанием (просто посмотрите на то как мы определяем D_k , на то, что условие в D_k для данной λ не выполняются, и на строение матрицы A) \Rightarrow (по предыдущей теореме) $A - \lambda I$ – невырожденна, но тогда λ не может являться собственным значением A (вспоминаем курс линала: характеристический многочлен и его корни). Получили противоречие. ■

Определение. Матрица D_k – круги Гершгорина.

Теорема (2-я теорема Гершгорина без доказательства). Если есть m кругов Гершгорина, образующих область G , то в G находится ровно m собственных значений.